

Teste técnico - Cientista de Dados Jr. - AeC Centro de Contatos

Descrição

Você foi contratado como cientista de dados para uma empresa de comunicação jornalística. Seu primeiro projeto é a criação de um classificador de categorias de notícias.

Conjunto de dados:

O conjunto de dados é composto por diversas notícias de jornais brasileiros. As variáveis disponíveis são o título, a data, categoria, e subcategoria da notícia.

Objetivos:

- Realizar uma análise de dados exploratória (EDA) do dataset fornecido;
- Criar um algoritmo que classifique as notícias de acordo com a sua categoria;
- Criar uma API simples para disponibilização dos resultados. Ela deve ter pelo menos um endpoint que realiza a classificação.

Critérios de Avaliação:

O teste técnico será avaliado seguindo a ordem de importância abaixo:

1. **Clareza de código:** obediência à boas práticas, comentários descritivos, padronização de estilo, etc.
2. **Entrega do resultado:** a ideia é termos um classificador que possa ser executado como em produção, que possamos fazer requisições e receber os resultados.
3. **Modelagem:** metodologia aplicada, técnicas, algoritmos e métricas utilizados.
4. **EDA:** resultados iniciais de análise, uso de tais resultados para modelagem.

Recursos adicionais:

Aqui vai algumas sugestões de ferramentas para uso durante a realização do teste. Vale notar que são apenas sugestões, caso queira utilizar outras, fique a vontade.

- Bibliotecas para NLP: [Spacy](#) e [NLTK](#)
- Bibliotecas para modelagem de dados: [Scikit-learn](#) e [Huggingface](#)
- Bibliotecas para produção: [Flask](#) e [FastAPI](#)

Etapas opcionais

Caso sobre algum tempo, construa um ecossistema de forma um pouco mais robusta, execute a API dentro de um contêiner docker, crie uma documentação para o projeto, talvez um setup de testes ou outro tipo de melhoria que conseguir pensar.

Observação

O objetivo é analisar a sua capacidade de construir um produto de dados do início ao fim, desta forma não foque tanto em obter os melhores resultados do modelo em si, é mais que você entregue algo funcional porém com resultados ruins do que um modelo ótimo sem uma infraestrutura de execução.